


## 线性判别分析



• 线性判别分析(Linear Discriminant Analysis)[Fisher, 1936]



LDA也可被视为一种 监督降维技术



建设单位: 大连理工大学

建设人: 刘倩



# **目录**CONTENT

- 01 PCA vs Fisher判别分析
- 02 Fisher判别分析
- 03 总结与讨论
- 04 课外阅读材料推荐








#### PCA vs Fisher判别分析

## 1 PCA vs Fisher判别分析



□ PCA将所有的样本作为一个整体对待,去寻找一个均方误差最小意义下的最优线性映射,而忽略了类别属性,即方差最大的方向不一定可用于分类





PCA能够识别字母O和Q的相似之处, 但很可能把二者的那个"尾巴"特征抛弃


| PCA           | Fisher判别分析  |
|---------------|-------------|
| 寻找保留最多信息的主轴方向 | 寻找用来有效分类的方向 |

## 1


-3

-4


#### PCA vs Fisher判别分析/LDA







投影到PCA的主成分方向



投影到LDA的主方向





## 2

#### Fisher判别分析



#### □ 问题描述:

有N个d-维的样本 $\mathbf{x}_1, \dots \mathbf{x}_N \in \mathbb{R}^d$ ,分属于两个不同的类别 $\omega_1$ 和 $\omega_2$ ,对应的样本子集为 $\mathcal{D}_1$ 和 $\mathcal{D}_2$ ,其中 $|\mathcal{D}_1| = N_1$ , $|\mathcal{D}_2| = N_2$ 。

**目标**: 确定一条直线 y (方向为w), 使 $\mathbf{x}_1$ , ...  $\mathbf{x}_N \in \mathbb{R}^d$ 投影到此直线的数据点  $y_1$ , ...  $y_N$  (分属于 $y_1$  和 $y_2$ 投影点子集)显著可分,即在投影  $y = \mathbf{w}^T \mathbf{x}$  下, 最大化准则函数

$$J(\mathbf{w}) = \frac{|\widetilde{m}_1 - \widetilde{m}_2|^2}{\widetilde{s}_1^2 + \widetilde{s}_2^2}$$

 $|\tilde{m}_1 - \tilde{m}_2|$  为投影后点的样本均值之差;


 $\tilde{s}_1^2 + \tilde{s}_2^2$  为投影后样本的总类内散布;

 $\frac{1}{N}(\tilde{s}_1^2 + \tilde{s}_2^2)$  为投影后数据总体方差估计.



$$J(\mathbf{w}) = \frac{|\widetilde{m}_1 - \widetilde{m}_2|^2}{\widetilde{s}_1^2 + \widetilde{s}_2^2}$$

□ 任务1: 求解最佳投影w使均值之间的差异相对于方差尽可能大。



□任务2:求解阈值,即一维空间中将两类分开的点的位置。

#### 意大连理工大学 Ballan University Of Technology

## **2** Fisher判别分析

□ 任务1: 求解最佳投影w使均值之间的差异相对于方差尽可能大。

$$J(\mathbf{w}) = \frac{|\widetilde{m}_1 - \widetilde{m}_2|^2}{\widetilde{s}_1^2 + \widetilde{s}_2^2}$$

目标:将J(·)写成w的表达式,求解使J(w)最大化的w

 $\triangleright$  定义 $\tilde{m}_i$ 为类别 $\omega_i$ 投影后的样本均值, $\mathbf{m}_i$ 为类别 $\omega_i$ 的样本均值,则

$$\widetilde{m}_i = \frac{1}{n_i} \sum_{y \in \omega_i} y = \frac{1}{n_i} \sum_{\mathbf{x} \in D_i} \mathbf{w}^T \mathbf{x} = \mathbf{w}^T \frac{1}{n_i} \sum_{\mathbf{x} \in D_i} \mathbf{x} = \mathbf{w}^T \mathbf{m}_i \qquad \widetilde{m}_i = \mathbf{w}^T \mathbf{m}_i$$

 $\triangleright$  定义 $\mathbf{S}_{\mathrm{B}}$ 为总类间散布矩阵,则  $\mathbf{S}_{\mathrm{B}}=(\mathbf{m}_{1}-\mathbf{m}_{2})(\mathbf{m}_{1}-\mathbf{m}_{2})^{T}$ ,则

$$|\widetilde{m}_1 - \widetilde{m}_2|^2 = (\mathbf{w}^T \mathbf{m}_1 - \mathbf{w}^T \mathbf{m}_2)^2 = \mathbf{w}^T (\mathbf{m}_1 - \mathbf{m}_2) (\mathbf{m}_1 - \mathbf{m}_2)^T \mathbf{w}$$

$$|\widetilde{m}_1 - \widetilde{m}_2|^2 = \mathbf{w}^T \, \mathbf{S}_{\mathrm{B}} \mathbf{w}$$

#### 意大连理工大学 Dalian University Of Technology

## **2** Fisher判别分析

□ 任务1: 求解最佳投影w使均值之间的差异相对于方差尽可能大。

$$J(\mathbf{w}) = \frac{|\widetilde{m}_1 - \widetilde{m}_2|^2}{\widetilde{s}_1^2 + \widetilde{s}_2^2}$$

目标:将/(·)写成w的表达式,求解使/(w)最大化的w

- $\triangleright$  定义 $\mathbf{S}_i$ 为类内散布矩阵,则  $\mathbf{S}_i = \sum_{\mathbf{x} \in D_i} (\mathbf{x} \mathbf{m}_i) (\mathbf{x} \mathbf{m}_i)^T$
- $\triangleright$  定义 $S_W$ 为总类内散布矩阵,则  $S_W = S_1 + S_2$ ;
- > 定义 $\tilde{s}_i^2$ 为投影后的类内散布,则

$$\tilde{s}_i^2 = \sum_{\mathbf{y} \in \omega_i} (\mathbf{y} - \tilde{\mathbf{m}}_i)^2 = \sum_{\mathbf{x} \in D_i} (\mathbf{w}^T \mathbf{x} - \mathbf{w}^T \mathbf{m}_i)^2 = \sum_{\mathbf{x} \in D_i} \mathbf{w}^T (\mathbf{x} - \mathbf{m}_i) (\mathbf{x} - \mathbf{m}_i)^T \mathbf{w}$$

$$\tilde{s}_i^2 = \mathbf{w}^T \mathbf{S}_i \ \mathbf{w}$$

$$\tilde{s}_1^2 + \tilde{s}_2^2 = \mathbf{w}^T \mathbf{S}_W \mathbf{w}$$



□ 任务1:求解最佳投影w使均值之间的差异相对于方差尽可能大。

$$J(\mathbf{w}) = \frac{|\widetilde{m}_1 - \widetilde{m}_2|^2}{\widetilde{s}_1^2 + \widetilde{s}_2^2}$$

目标:将/(·)写成w的表达式,求解使/(w)最大化的w

$$J(\mathbf{w}) = \frac{|\widetilde{m}_1 - \widetilde{m}_2|^2}{\widetilde{s}_1^2 + \widetilde{s}_2^2} = \frac{\mathbf{w}^T \mathbf{S}_B \mathbf{w}}{\mathbf{w}^T \mathbf{S}_W \mathbf{w}}$$

这个目标函数在数学物理中常用,使得/(w)最大化的w应满足:

$$\mathbf{S}_{\mathrm{B}}\mathbf{w} = \lambda \mathbf{S}_{\mathrm{W}} \mathbf{w}$$

$$S_{BW}$$
 总是位于 $(m_1 - m_2)$ 的方向上  $w = S_{W}^{-1}(m_1 - m_2)$ 




$$\mathbf{w} = \mathbf{S}_{W}^{-1}(\mathbf{m}_{1} - \mathbf{m}_{2})$$



□ 任务2: <mark>求解阈值y0</mark>, 即一维空间中将两类分开的点的位置。

#### 使用最佳边界判决条件:

若 
$$y = \mathbf{w}^T \mathbf{x} < y_0$$
,则属于类别 $\omega_1$ ;  
反之,则属于类别 $\omega_2$ .



#### 实际操作:

- 1. 对投影后的数据进行平滑,或用一维高斯函数进行拟合;
- 2. 阈值 $y_0$ 可以选择为使两个类的后验概率相同的y值。



#### 2 Fisher判别分析——多重判别分析

#### □ 将Fisher判别准则从二类别问题推广到c类别问题

- 》判别函数个数: c-1,  $|\mathcal{D}_1|=N_1$ , ...,  $|\mathcal{D}_c|=N_c$ ,  $\mathbf{m}_i=\frac{1}{N_i}\sum_{\mathbf{x}\in\mathcal{D}_i}\mathbf{x}$
- $\triangleright$  投影问题: 从d维空间向c -1维空间做投影 (假设 $d \ge c$ )

$$\triangleright$$
 总类内散布矩阵  $\mathbf{S}_{\mathrm{W}} = \sum_{i=1}^{c} \mathbf{S}_{i}$  其中 $\mathbf{m} = \frac{1}{N} \sum_{\mathbf{x}} \mathbf{x} = \frac{1}{N} \sum_{i=1}^{c} N_{i} \mathbf{m}_{i}$ 

 $\triangleright$  总类间散布矩阵  $\mathbf{S}_{\mathrm{B}} = \sum_{i=1}^{3} N_i (\mathbf{m}_i - \mathbf{m}) (\mathbf{m}_i - \mathbf{m})^T$ 

$$J(\mathbf{W}) = \frac{|\mathbf{W}^T \mathbf{S}_{\mathbf{B}} \mathbf{W}|}{|\mathbf{W}^T \mathbf{S}_{\mathbf{W}} \mathbf{W}|} \qquad \mathbf{其中} \ \mathbf{W} \in \mathbb{R}^{d \times (c-1)}$$

使J(W)最大化的最优矩阵W的列向量是 $S_W^{-1}S_B$ 的最大特征值对应的特征向量


$$S_{\mathrm{W}}^{-1}S_{\mathrm{B}}w_{i}=\lambda_{i}\;w_{i}$$



#### Fisher判别分析——具体步骤

- 1. 利用训练样本集合计算类内散布矩阵  $S_w$  和类间散度矩阵  $S_B$ ;
- 2. 计算  $S_W^{-1}S_B$  的特征值;
- 3. 选择非0的c-1个特征值对应的特征矢量组成一个变换矩阵 W=[w<sub>1</sub>, w<sub>2</sub>, ..., w<sub>c-1</sub>];
- 4. 训练和识别时,每一个输入的d维特征矢量x可以转换为c-1维的新特征矢量  $y=W^Tx$





## 总结与讨论



#### 总结与讨论



| PCA           | Fisher判别分析  |
|---------------|-------------|
| 寻找用于有效表示的主轴方向 | 寻找用来有效分类的方向 |

- □ 经Fisher判别分析变换后,新的坐标系不是一个正交坐标系
- □ 新的坐标维度最多为c-1, c为类别数
- □ 只有当样本数足够多时,才能够保证类内散度矩阵Sw为非奇异矩阵 (存在逆阵),而样本数少时Sw可能是奇异矩阵



#### 课外阅读材料推荐



#### □ 特征降维——线性方法 (PCA和Fisher判别分析相关)

- > Eigenfaces for Recognition. M. Turk and A. Pentland
- ➤ Using Discriminant Eigenfeatures for Image Retrieval. D. Swets, J. Weng
- ➤ Eigenfaces vs. Fisherfaces: Recognition Using Class Specific Linear Projection. P. Belhumeur, J. Hespanha, and D. Kriegman
- > PCA versus LDA. A. Martinez, A. Kak



# 谢谢大家!